Instrucciones de Proyecto (Competencia)

Curso Aprendizaje de Máquina 2026-10

1 Introducción

Bienvenidos al proyecto del curso. El presente proyecto consiste en una competencia académica en la que participarán grupos de todas las secciones. El desafío propuesto consiste en desarrollar un sistema de clasificación de textos según su década de origen. El objetivo principal es diseñar un modelo capaz de predecir la década en la que fue escrito un párrafo determinado.

La competencia se divide en dos etapas. En la primera, los participantes deberán emplear técnicas tradicionales de aprendizaje automático, sin recurrir al uso de redes neuronales ni arquitecturas profundas. En la segunda etapa, será obligatorio utilizar redes neuronales profundas, así como implementar estrategias de aumento de datos.

La competencia es exclusiva para estudiantes del Curso de Aprendizaje de Máquina de la Universidad de los Andes inscritos en el primer semestre del 2026-10.

2 Resultados de Aprendizaje

Con esta actividad se busca que el estudiante pueda poner en práctica el desarrollo de una solución completa de *machine learning* para un problema de clasificación de texto. Tras realizar esta actividad se espera que el estudiante esté en capacidad de:

1. Proponer y seleccionar modelos de *machine learning* que permitan resolver un problema de clasificación de texto.
2. Identificar y aplicar diferentes técnicas de procesamiento de texto.
3. Representar el texto de manera que permita el uso de modelos de *machine learning*.
4. Hacer uso de los datos para entrenar y evaluar el desempeño del modelo.
5. Probar distintos modelos para encontrar la mejor solución para el problema particular.

3 Descripción de la Competencia

La competencia consiste en la construcción de un sistema capaz de clasificar textos según la década en que fueron escritos. El objetivo principal es desarrollar un modelo que, dado un párrafo como entrada, prediga de manera precisa la década de origen del texto.

3.1 Plataforma

Kaggle es una plataforma en línea que permite a investigadores, profesionales y estudiantes participar en competencias de ciencia de datos y aprendizaje automático. En Kaggle, los usuarios pueden acceder a conjuntos de datos, desarrollar modelos, colaborar con otros participantes y presentar sus soluciones para ser evaluadas automáticamente mediante un sistema de puntuación. Además, ofrece recursos educativos y foros de discusión que facilitan el aprendizaje y la resolución de problemas. Para la competencia del curso se utilizará la plataforma Kaggle. En un documento anexo publicado en Bloque Neon va a encontrar un tutorial de registro a la plataforma, registro a una competencia de prueba y la explicación de cómo realizar envíos.

3.2 Descripción de los Datos

Se proporcionan los siguientes archivos:

- **train.csv**: contiene alrededor de 31,400 ejemplos de entrenamiento con columnas:
  - `text` (str): texto a clasificar.
  - `decade` (int): década del texto expresada como los tres primeros dígitos del año (ejemplo: para el año de 1572 la década es 157).
- **eval.csv**: archivo de evaluación con columnas:
  - `id`: identificador único del ejemplo de prueba.
  - `text`: texto a clasificar.

3.3 Archivo de respuesta

El archivo de respuesta debe contener el siguiente formato:

```
id,answer
2,150
5,162
6,173
...
```

Cada `id` en el conjunto de prueba debe tener un valor en la columna `answer`, indicando la década predicha por el modelo.

Este archivo de respuesta debe ser enviado a través de la plataforma Kaggle, y será utilizado para la evaluación de su propuesta, así como para su clasificación en el leaderboard de la competencia. Una parte de los resultados se empleará para calcular el score público, el cual estará disponible durante toda la competencia, mientras que otra parte se utilizará para el score privado, que determinará el resultado final y será revelado un día después de la finalización de la competencia.

4 Parte 1: Machine Learning Clásico

La primera etapa de la competencia se centra en la aplicación de algoritmos clásicos de aprendizaje automático para la tarea de clasificación.

4.1 Requisitos técnicos

Recuerde que su modelo no tendrá validez si no cumple los requisitos que se mencionan a continuación. Por lo tanto, obtendrá una calificación de 0 en la primera entrega. Los requisitos son los siguientes:

- No se permite el uso de técnicas de aprendizaje profundo, incluyendo modelos de lenguaje basados en arquitecturas *transformer*.
- Únicamente se pueden emplear modelos de clasificación desarrollados con la librería `scikit-learn`, siempre que no contravengan los demás requisitos aquí establecidos.
- La competencia debe resolverse exclusivamente mediante el uso de modelos clásicos de aprendizaje automático y técnicas de representación de texto abordadas durante la primera parte del curso.
- Para la revisión en Bloque Neón, se debe subir un único modelo, el cual debe corresponder al envío que haya obtenido el mejor resultado en la competencia de Kaggle de su grupo.
- Los resultados deben ser completamente replicables a partir de los entregables presentados en la plataforma de Bloque Neón.

4.2 Entregables en Bloque Neón

En la semana 11 del curso se habilitará una actividad en la que usted y su grupo deberán subir los siguientes entregables, correspondientes únicamente al modelo final con el que obtuvieron los mejores resultados en la tabla de líderes pública de la competencia de Kaggle:

1. Jupyter Notebook que se utilizó para realizar la implementación y el entrenamiento del clasificador de texto.
2. El archivo donde se guardó el modelo de `scikit-learn` entrenado. El modelo debe guardarse haciendo uso de las librerías `pickle` o `joblib`.

4.3 Rúbrica de Evaluación

La nota del proyecto se compone de los siguientes criterios:

Table 1: Composición de la nota del proyecto - Parte 1

Item	**Porcentaje de la nota**
Participación en la competencia	20%
Superar la línea base (ver en Kaggle)	40%
Percentil obtenido en la competencia	40%

4.3.1 Participación en la competencia

Para que sea considerada su participación en la competencia su grupo debe realizar al menos 5 envíos `diferentes` en la plataforma de Kaggle. La idea es evidenciar que el grupo trato de mejorar su enfoque inicial.

4.3.2 Superar la línea base

El equipo del curso preparo una linea base (i.e. modelo) que debe superar. Esta linea base la encuentra en el leaderboard de la competencia en Kaggle.

4.3.3 Percentil obtenido en la competencia

El 40% restante de la nota final se obtiene de acuerdo al desempeño del modelo desarrollado con su grupo en la competencia de Kaggle. Al cerrar la competencia se generan unos puntajes finales, y su nota en este rubro dependerá del desempeño obtenido. El porcentaje obtenido de este rubro se calcula de la siguiente manera:

Desempeño obtenido	Porcentaje del rubro
$<$ percentil 25	0%
$\geq$ percentil 25 y $<$ percentil 50	50%
$\geq$ percentil 50 y $<$ percentil 75	75%
$>$ percentil 75	100%

Table 2: Distribución del porcentaje del rubro según desempeño obtenido

4.3.4 Fechas Importantes Parte 1

- Fecha de apertura: **Semana 4**
- Fecha de finalización: **Semana 11 (13 de abril 10pm)**

4.4 Enlaces de la Competencia Kaggle Parte 1

- **Enlace de Invitación**: Kaggle Invitation Parte 1

5 Parte 2: Deep Learning y Aumentación de Datos

En esta segunda etapa de la competencia, usted y su grupo deberán abordar la tarea de clasificación utilizando arquitecturas profundas de aprendizaje automático. Se permite emplear modelos de aprendizaje profundo como MLPs, redes neuronales convolucionales (CNN), recurrentes (RNN), entre otras.

5.1 Requisitos técnicos

Para esta parte, es fundamental cumplir con los siguientes requisitos para que su modelo sea considerado válido:

- Es obligatorio el uso de técnicas y arquitecturas de aprendizaje profundo, incluyendo transferencia de aprendizaje, y modelos preentrenados.
- Es posible aplicar estrategias de aumentación de datos, tales como la incorporación de fuentes de datos abiertas disponibles de las épocas correspondientes.
- Se permite el uso de datos externos siempre que la licencia lo autorice, puedan ser referenciados adecuadamente, descargados y distribuidos.
- En caso de utilizar datos adicionales, estos deben ser referenciados de manera clara, incluyendo la página de donde fueron obtenidos y la licencia explícita de uso.
- Está permitido el uso de datos sintéticos para entrenar los modelos, pero debe describir en detalle como realizo la construcción.
- Está estrictamente prohibido utilizar los datos de prueba para el entrenamiento de los modelos.

5.2 Entregables en Bloque Neón

En la semana 14 del curso se habilitará una actividad en la que usted y su grupo deberán subir los siguientes entregables, correspondientes únicamente al modelo final con el que obtuvieron los mejores resultados en la tabla de líderes pública de la competencia de Kaggle:

1. Jupyter Notebook utilizado para la implementación, entrenamiento y evaluación del modelo de aprendizaje profundo.
2. El archivo con el modelo entrenado, guardado utilizando las librerias vistas en clase (`tensorflow`, `keras`, etc.).
3. Un documento adicional que incluya las referencias a los datos externos utilizados, especificando la fuente, el enlace y la licencia de cada conjunto de datos.

5.3 Rúbrica de Evaluación

La calificación de esta parte del proyecto sigue la misma lógica de la pate 1.

5.3.1 Fechas Importantes Parte 2

- Fecha de finalización: **Semana 16**

5.4 Enlaces de la Competencia Kaggle Parte 2

- **Enlace de Invitación**: Será informada posteriormente